城市人口预测与分析

——基于机器学习与城市级自适应集成模型

最终验证 MSE	较 V5 MSE 下降	预测城市数	2023 预测总人口
679.94	**7.49%**	**40**	**28564 万人**

课程项目研究报告

项目成员分工和推进日志

一、总体节奏

周	主线	目标
第 1 周	数据 + 基线	跑通 cleaned_panel.csv + 基线模型，出第一版 submission.csv
第 2 周	模型 + 评估	滚动回测 + 多模型对比 + 误差诊断，锁定主模型
第 3 周	优化 + 交付	趋势约束/融合、加权融合、最终提交 + 文档

核心原则：

- 第 1 周末必须有能提交的版本，哪怕很粗糙；
- 第 2 周锁定主模型，不再大改；
- 第 3 周只做优化和交付，不引入新方法。

二、四人交叉分工

成员	第 1 周主责	第 2 周主责	第 3 周主责
王凯凤	数据清洗、面板构建	特征因果性检查	工程整合、提交
林诗怡	特征工程、基线模型	滚动回测、模型实现	优化实验复现
王恩嘉	评估指标、误差诊断	多模型对比、误差分析	趋势约束、融合
赖彦然	路径管理、代码整合	结果整理、可视化	文档、Dockerfile、决赛方案

三、第 1 周：数据 + 基线

目标：跑通数据，出第一版 submission.csv。

任务：

- 读取 7 个文件，清洗、合并、对齐；明确目标口径 pr_pop；构建 cleaned_panel.csv。
- 构造基础特征（滞后、增长率、滑动窗口）；实现基线模型 NaiveFlat、Drift3、Drift5；递归预测 2023，生成第一版 submission.csv。
- 设计评估指标 MSE、RMSE、MAE、MAPE；写 evaluation.py 初版。
- 统一路径管理，用 __file__ 自动定位 CSV；整合代码到 main.py。

周末交付：

- cleaned_panel.csv
- rolling.py 或 main.py
- 第一版 submission.csv
- evaluation.py 初版

周末同步：确认目标口径；确认提交格式；确认第一版 MSE。

四、第 2 周：模型 + 评估

目标：滚动回测 + 多模型对比，锁定主模型。

任务：

- 实现 Ridge、LightGBM、Blend；实现滚动原点回测（验证年 v 用 year ≤ v-2 训练）；LightGBM 早停，内部验证集按完整年份切；输出 model_comparison.csv。
- 多指标评估 MSE、RMSE、MAE、MAPE、SMAPE、R^2、score；按城市规模 large/medium/small 分组指标；误差诊断（分年度、分城市、最大误差样本）；输出 year_mse_rolling.csv、city_mse_rolling.csv。
- 检查特征因果性，防止泄露；确认协变量统一滞后 2 期。
- 整理结果，画真实值 vs 预测值散点；准备第 3 周优化实验的代码框架。

周末交付：

- model_comparison.csv
- year_mse_rolling.csv、city_mse_rolling.csv
- 误差诊断报告

周末同步：锁定主模型（按平均 MSE 选）；确认误差主要来源（年份、城市、规模）；确定第 3 周优化方向。

五、第 3 周：优化 + 交付

目标：优化主模型，完成最终提交和文档。

任务：

- 趋势约束 pred = clip(pred, pop_2021 * (1 ± ratio))；趋势外推融合 final = alpha * model + (1-alpha) * trend；加权融合替代简单平均；2020/2021 降权；用滚动验证选最优参数。

- 工程整合（统一入口、配置外置）；生成最终 submission.csv；封装 Dockerfile、源代码压缩包；写 README、运行说明、结果说明。
- 复现优化结果，确认不是偶然；检查提交格式。
- 辅助调参；确认最终模型可复现。

周末交付：

- 最终 submission.csv
- optimization_report.md
- Dockerfile、README.md
- 决赛方案压缩包

摘要

城市人口规模受人口结构、就业、工资、城镇化水平与居民生活水平等多维因素影响，科学预测城市人口对城市规划、公共资源配置与经济社会发展具有重要现实意义。本文面向 CCF 城市人口预测赛题，基于 40 个城市 2006—2021 年的多维面板数据（清洗后 717 条记录、21 个字段），建立机器学习模型对 2023 年各城市常住人口规模进行预测，并输出符合竞赛格式要求的提交文件。

方法上，本文坚持严格的“时间因果”约束：所有特征仅使用目标年份前两年（含）及更早的信息，杜绝未来信息泄漏；采用 2017—2021 年五折扩展窗口滚动验证（共 200 个 OOF 样本）评价模型。在模型体系上，依次构造历史趋势基线（Trend）、Ridge 回归、ExtraTrees 与 LightGBM 四种基础模型，其中城市身份以 One-Hot 编码显式纳入树模型，并采用 OOF 自动优化集成权重。

针对不同城市人口增长模式差异显著、统一模型存在系统性偏差的问题，本文提出 V6 城市级自适应模型：以 ExtraTrees 为统一主模型学习城市间的共同规律，再利用每个城市在滚动验证中产生的历史预测残差，经时间衰减加权（衰减系数 0.6）并向全局残差收缩（收缩参数 2.0）后，得到城市级残差校正项。该设计既避免了为 40 个城市分别训练独立模型导致的样本过少与过拟合，又保留了城市自身“长期偏高或偏低”的个性信息。

严格滚动验证结果表明：V6 城市自适应模型的总体 MSE 为 679.944，RMSE 为 26.076，MAE 为 11.920，较 V5 全局集成模型的嵌套 OOF MSE（734.994）下降 7.49%，较普通 ExtraTrees 的 OOF MSE（715.996）亦有明显改善；ExtraTrees 在四种基础模型中表现最优（MSE 715.996），集成权重自动收敛至 ExtraTrees（约 100%）。分年度来看，2020、2021 年误差显著高于前期，印证了 2020 年第七次人口普查导致的数据结构变化对预测的冲击。最终模型对 40 个城市 2023 年常住人口进行预测，预测总人口约 28564.38 万人，并完成基于城市增长率与模型分歧的异常预测诊断。

关键词：城市人口预测；滚动验证；机器学习；ExtraTrees；城市级自适应；残差校正；LightGBM

目录

项目成员分工和推进日志 2
一、总体节奏 2
二、四人交叉分工 2
三、第 1 周：数据 + 基线 2
四、第 2 周：模型 + 评估 3
五、第 3 周：优化 + 交付 3
摘要 5
目录 6
1 研究背景与问题描述 1
1.1 研究背景与意义 1
1.2 赛题任务与评价指标 1
1.3 人口预测问题的特点 2
2 数据来源与数据预处理 3
2.1 数据来源与结构 3
2.2 数据清洗 3
2.3 缺失值处理 4
2.4 异常值处理 5
3 人口数据探索性分析 5
3.1 城市人口规模分析 5
3.2 人口变化趋势分析 6
3.3 城市增长类型划分 7
3.4 人口与社会经济因素相关性分析 8
4 人口预测特征工程 9
4.1 特征工程总体思路 9
4.2 历史人口特征 9
4.3 滞后与差分特征 9

4.4 历史趋势特征 9
4.5 人口结构特征 10
4.6 社会经济特征 10
4.7 城市相对特征 10
4.8 特征重要性分析 10
5 人口预测模型构建 11
5.1 趋势基线模型（Trend） 11
5.2 Ridge 回归模型 12
5.3 ExtraTrees 模型 12
5.4 LightGBM 模型 12
5.5 模型集成策略 12
6 时间滚动验证与模型评价 13
6.1 时间因果约束 13
6.2 滚动验证方案 13
6.3 评价指标体系 14
6.4 各模型 OOF 结果比较 14
7 V6 城市级自适应模型 15
7.1 城市异质性分析 15
7.2 城市历史残差 15
7.3 时间衰减加权机制 15
7.4 城市级残差校正 16
7.5 V6 模型完整流程 16
8 模型结果与 2023 年人口预测 17
8.1 V5 与 V6 对比 17
8.2 V6 滚动验证结果 18
8.3 40 城市 2023 年人口预测结果 19
8.4 异常预测诊断 20

9 模型可靠性与局限性 20
9.1 模型优势 20
9.2 模型局限 21
9.3 结果可靠性分析 21
10 结论 21
附录 A 数据字段说明 1
附录 B 核心 Python 代码 1
附录 C 模型运行结果 1
C.1 各模型 OOF 指标 1
C.2 城市级校正量 1
附录 D 最终提交文件 1

1 研究背景与问题描述

1.1 研究背景与意义

人口是城市经济社会活动的基础单元。常住人口规模及其变动，既是城市规划编制、公共资源配置（教育、医疗、交通、住房）与基础设施建设的直接依据，也是衡量城市吸引力、发展潜力与承载能力的重要指标。准确、前瞻地预测城市人口，能够为决策者在空间规划、产业布局、公共服务供给与财政安排等方面提供定量支撑，从而提升城市治理的科学性与有效性。

城市人口规模并非孤立存在，而是受到人口年龄结构、就业状况、工资水平、城镇化率、居民收入与消费水平等多维因素的共同影响。这些因素既相互关联又随时间演化，使得人口预测成为一个典型的“多维时序回归”问题：既需要在时间维度上捕捉人口自身的延续性，也需要在横截面上刻画不同城市之间的结构差异。

基于上述背景，本课题利用给定 40 个城市的多维人口与社会经济数据，对城市人口的变化规律进行系统分析，并在此基础上建立预测模型，对 2023 年各城市常住人口规模进行预测。课题的意义在于：一方面形成一套从数据清洗、特征工程、模型构建到严格验证、结果诊断的完整分析流程；另一方面，通过引入“城市级自适应”机制，探索在统一模型框架下兼顾城市异质性的可行路径，为同类区域人口预测问题提供方法参考。

1.2 赛题任务与评价指标

1.2.1 赛题任务

本课题所对应的赛题为“城市人口预测”：根据多个城市近年的人口、年龄结构、就业、工资、生活水平、城镇化率等数据，建立人口预测模型，预测各城市 2023 年的常住人口规模。

- 数据范围：40 个城市，2006—2021 年多维面板数据（清洗后 717 行、21 个字段）。
- 目标变量：pr_pop，即常住人口（万人）。
- 提交格式：city_id、year、pred 三列，其中 pred 为 2023 年预测人口。

1.2.2 评价指标

本模型以均方误差（MSE）为核心评价指标，并以其衍生的 score 作为最终得分，同时辅以 RMSE、MAE、R^2 用于全面评估模型精度：

$$\mathrm{MSE} = (1/n)\,\Sigma(i = 1..n)\,(y_i - \hat{y}_i)^2$$

$$\mathrm{score} = 1 / (1 + \mathrm{MSE})$$

其中 y_i 为第 i 个样本的真实人口，$\hat{y}_i$ 为模型预测人口，n 为样本数。MSE 对误差取平方，因而对大幅偏差极为敏感；而 score 为 MSE 的单调递减函数，MSE 越小得分越高。此外还报告 RMSE = √MSE（与人口量纲一致，便于解释），$\mathrm{MAE} = (1/n)\,\Sigma|y_i - \hat{y}_i|$（平均绝对误差），以及 R^2（决定系数，衡量模型解释力）。

1.3 人口预测问题的特点

1.3.1 时间序列特征

人口具有明显的时间连续性。当前年份的人口规模通常与前几年的人口规模高度相关，即 P(t) 与 P(t−1)、P(t−2) 等存在强依赖关系。这一特性决定了：一方面，历史人口是最重要的基础预测信号；另一方面，模型评价必须遵循时间因果约束，否则极易发生“用未来预测过去”的信息泄漏。

1.3.2 城市异质性

不同城市的人口增长模式差异显著，大体可分为高速增长、稳定增长、人口收缩（或低增长）、波动型（含普查跳变）等类型。人口规模从一百余万到近两千万、增长率从明显下降到大步扩张并存。若对全部城市使用完全相同的预测规则，则可能对高速增长城市系统性低估、对收缩城市系统性高估。这构成 V6 城市级自适应机制设计的直接动因。

1.3.3 多因素影响

人口变化不仅取决于历史人口，还受到年龄结构、就业状况、工资水平、城镇化率、居民收入与消费水平等因素的影响。因此，有效的预测模型应融合多维社会经济特征，而非仅依赖人口序列本身。

1.3.4 2020 年人口普查的结构性影响

2020 年开展了第七次全国人口普查，普查口径与抽样推算可能存在系统性差异，使得 2019→2020 年的人口数据可能呈现明显的结构性跳变。若模型将这种跳变全部解释为正常的自然增长趋势并向外推，将导致较大误差。因此，模型需识别并处理普查断层——这正是 V6 趋势基线修正与分年度误差分析的重要内容。

2 数据来源与数据预处理

2.1 数据来源与结构

课题原始数据来源于多个分主题数据文件，经统一清洗与整合后形成面板数据文件 cleaned_panel(1).csv。该文件为“城市 × 年份”的长表结构，共 717 行、40 个城市、2001—2021 年，包含 21 个字段，覆盖人口、结构、就业、经济与生活水平等维度。目标变量为 pr_pop（常住人口，万人）。各字段按类别整理如下表。

类别	字段	说明
人口	pr_pop / r_pop	常住人口 / 户籍人口（万人）
城镇化	urban_rate / density	城镇化率 / 人口密度
年龄结构	age_0_14 / age_15_64 / age_65plus	0–14 岁 / 15–64 岁 / 65 岁以上人口
就业	employees / unemp_rate	就业人数 / 失业率
产业就业	pi_emp / si_emp / ti_emp	第一 / 第二 / 第三产业就业人数
工资	avg_wage	平均工资
收入	disp_income / towner_income / rural_income	可支配收入 / 城镇 / 农村居民收入
消费	cons_exp / towner_cons / rural_cons	消费支出 / 城镇 / 农村消费
目标	pr_pop	常住人口（预测目标）

表 2-1 面板数据字段分类一览

2.2 数据清洗

多源数据在字段命名、统计口径与时间粒度上存在差异，需统一处理后再行建模。数据清洗主要包括四个方面：

- 字段统一：统一城市名称、城市编号（city_id）、年份与指标名称，消除多源数据间的命名差异。
- 时间一致性：确保“city_id + year”构成唯一的城市—年份观测，无重复、无遗漏，面板结构规整。
- 单位与口径统一：人口类指标统一为“万人”，收入与工资类指标统一为可比口径。
- 类型校准：对 city_id 等标识字段按字符串处理，防止被数值化后引入无意义的排序信息。

2.3 缺失值处理

面板数据中部分字段存在不同程度的缺失，尤其是年龄结构、收入、消费等分主题数据在早期年份覆盖不全。各字段缺失率统计如下表。

字段	缺失数	缺失率（%）	字段	缺失数	缺失率（%）
pr_pop	25	3.49	si_emp	103	14.37
r_pop	11	1.53	ti_emp	103	14.37
urban_rate	77	10.74	avg_wage	49	6.83
density	59	8.23	disp_income	563	78.52
age_0_14	637	88.84	cons_exp	556	77.55
age_15_64	642	89.54	towner_cons	447	62.34
age_65plus	641	89.4	rural_cons	511	71.27
unemp_rate	72	10.04	towner_income	385	53.7
employees	98	13.67	rural_income	454	63.32
pi_emp	103	14.37	—	—	—

表 2-2 各字段缺失情况统计

针对不同变量的缺失特点，采取差异化处理策略：

- 对缺失率较低且时序平稳的核心变量（如 pr_pop、r_pop、density），以城市自身历史序列为主，采用线性插值、前向/后向填充与按城市历史数据补全相结合的方式。
- 对缺失率较高的年龄结构、收入、消费等变量，优先使用该城市可观测年份的信息，并引入“变量可用性标志”（avail）作为特征，让模型显式感知数据可得性，避免用填值掩盖缺失模式。

- 对树模型，采用中位数填充缺失值；对线性模型，采用标准化前的中位数填充，从而在保留信息的同时保持数值稳定性。

2.4 异常值处理

针对可能的数据异常，重点进行以下检查与处理：

- 人口突增/突降：检测相邻年份人口异常跳变，结合普查断层的背景判断是真实结构变化还是录入错误，对明显错误予以修正。
- 负值与不合理取值：检查人口、就业、工资等本应为正值的指标，剔除或修正负值等明显异常。
- 重复记录：确保每个城市—年份仅保留一条有效记录。
- 不合理比例：检查年龄占比、产业就业占比等比例是否落在合理区间，识别口径错位。

值得强调的是，对于 2020 年前后的人口跳变，本课题并未简单将其视为噪声剔除，而是作为“已发生的可观测结构变化”加以识别与建模处理（详见第 5 章趋势基线中的普查修正），既保留了真实信息，又避免了向外推时的失真。

3 人口数据探索性分析

3.1 城市人口规模分析

对 40 个城市 2021 年常住人口截面进行分析发现，城市间人口规模差异悬殊。人口最大城市达 1870.0 万人，最小城市仅 116.0 万人，均值 652.2 万人，中位数 533.5 万人，呈明显右偏分布——少数超大城市显著拉高均值，而多数城市集中在中低规模区间。人口规模前五的城市为 city28、city21、city5、city3、city17，后五位为 city4、city39、city20、city23、city10。各城市 2021 年人口规模分布如图 1 所示。

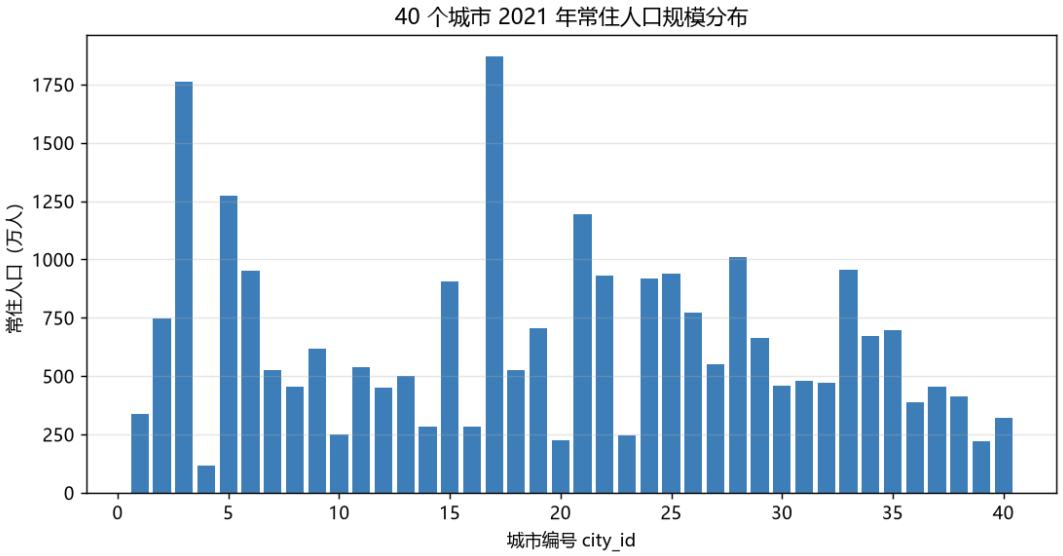


图 1　40 个城市 2021 年常住人口规模分布

人口规模的巨大跨度意味着：在平方误差（MSE）为官方指标的前提下，人口规模较大的城市在总分中天然占据更高权重。因此，模型不仅要对中位城市准确，还必须对超大城市的绝对误差加以有效控制，这也从侧面说明引入城市身份信息与城市级校正的必要性。

3.2 人口变化趋势分析

对典型城市 2001—2021 年的人口时序进行考察，可清晰识别出四类不同的变化模式（图 2）：高速增长型（如 city3，人口持续较快上升）、稳定增长型（如 city1，缓慢平稳上行）、收缩/低增长型（如 city8，人口长期下降或停滞）、普查跳变型（如 city2，在 2020 年前后出现明显阶跃）。

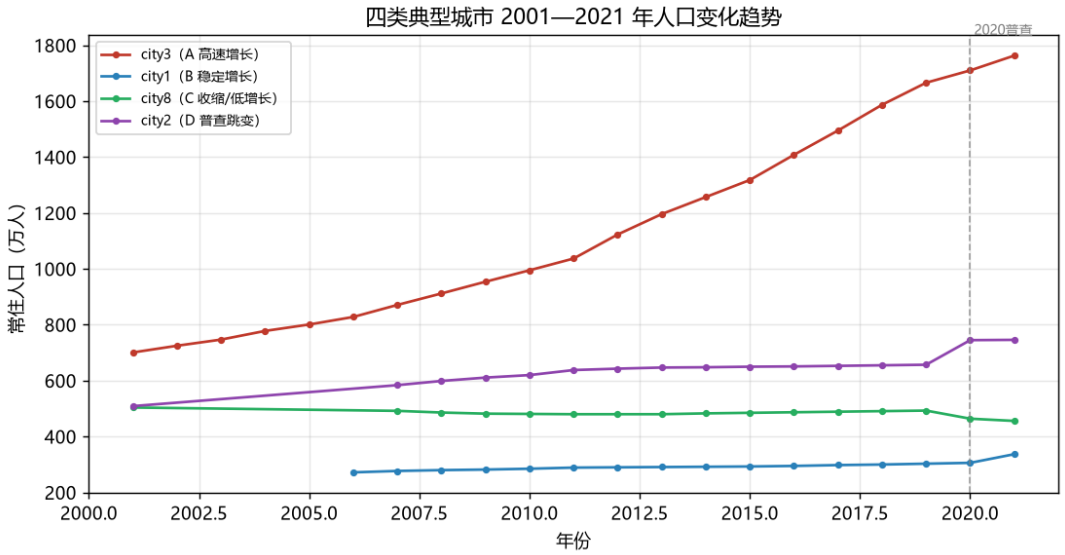


图 2 四类典型城市 2001—2021 年人口变化趋势

可以看出，城市人口轨迹具有强烈的个性化特征：趋势的斜率、波动幅度与阶段突变各不相同。这直接决定了“一个统一模型 + 一个固定规则”难以对所有城市同时达到高精度，也为城市级自适应校正提供了现实依据。

3.3 城市增长类型划分

为刻画城市异质性，依据各城市历史 5 年复合增长率与历史波动率，并叠加 2020 年普查跳变识别，将 40 个城市划分为四类增长类型（该划分仅用于诊断与解释，不直接切换预测模型）：

增长类型	城市数量	城市列表	特征
A 高速增长	8	city3、city10、city11、city17、city19、city21、city23、city25	5 年复合增长率较高
B 稳定增长	17	city1、city6、city7、city9、city13、city15、city16、city20、city26、city28、city29、city30、city31、city33、city37、city38、city39	增长平稳、波动较小
C 收缩/低增长	10	city4、city8、city12、city14、city27、city32、city34、city35、city36、city40	增长率低或人口收缩
D 普查跳变	5	city2、city5、city18、city22、city24	2020 年前后存在明显跳变

表 3-1 40 个城市增长类型划分

由表可见，稳定增长城市占主体（17 城），高速增长（8 城）与收缩/低增长（10 城）并存，另有 5 城受普查跳变影响。这种结构性分化是后续模型设计必须面对的核心难点。

3.4 人口与社会经济因素相关性分析

为考察人口与经济变量的关联，以 2021 年截面数据计算人口与各社会经济变量的 Pearson 相关系数，结果如图 3 所示。

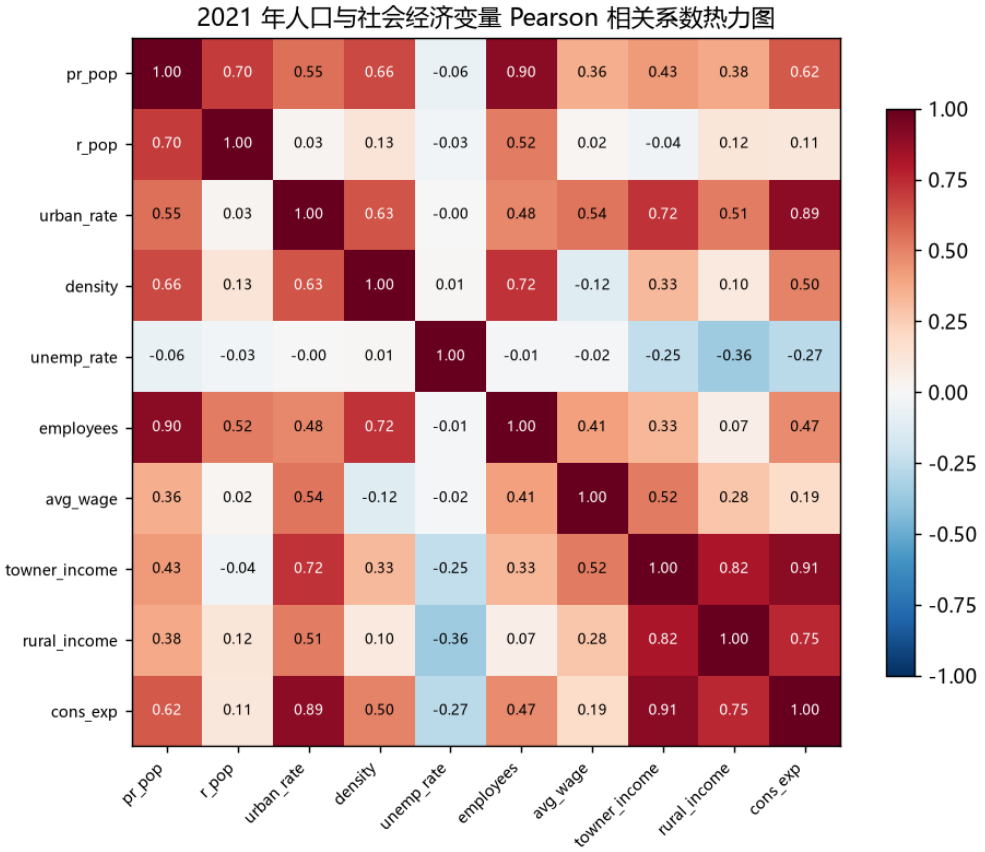


图 3 2021 年人口与社会经济变量 Pearson 相关系数热力图

人口与核心经济变量的相关系数排序为：就业人数（0.901）＞户籍人口（0.699）＞人口密度（0.659）＞消费支出（0.617）＞城镇化率（0.548）＞城镇居民收入（0.427）＞农村居民收入（0.382）＞平均工资（0.362），而与失业率呈较弱负相关（−0.063）。

这一结果揭示了两点重要信息：其一，就业规模与人口规模高度同步，反映“就业—人口”集聚效应；其二，收入、消费、工资等经济变量虽与人口相关但并非简单线性，

提示应在模型中加入多期滞后与非线性的建模能力。上述发现为第 4 章特征工程提供了方向性依据。

4 人口预测特征工程

4.1 特征工程总体思路

特征工程遵循两条核心原则：

第一，时间因果约束。所有特征的信息截止点为 cut = 目标年份 − 2（即只使用目标年份前两年及更早的数据），确保任何特征都不含未来信息。

第二，多维覆盖。融合人口历史、结构、趋势与社会经济等多类特征，使模型能够从不同角度刻画人口变化。

对每个样本，提取滞后人口、人口差分与比率、历史趋势、人口结构、社会经济及其滞后差分等特征，同时以信息截止点为准计算 2020 年普查断层标志，杜绝“偷看”未来。

4.2 历史人口特征

构造目标年份前 2 至 7 年的常住人口滞后项 pop_lag2、pop_lag3、……、pop_lag7，作为最强的基础时序信号，捕捉人口自身的延续性。

4.3 滞后与差分特征

为刻画人口增量的变化节奏，构造相邻滞后项之差与比率：

$$\boldsymbol{pop_diff_(a,b) = pop_lag_a - pop_lag_b}$$

$$\boldsymbol{pop_rate_(a,b) = pop_lag_a \,/\, pop_lag_b - 1}$$

差分反映绝对增量，比率反映增长速度，二者共同描述人口变化的“量”与“速”。

4.4 历史趋势特征

对城市截至信息截止点的完整人口历史，计算以下趋势与波动指标：

- hist_slope：人口序列的最小二乘斜率，刻画长期增长动能。

- hist_cagr3 / hist_cagr5：3 年、5 年复合增长率，刻画中期增速。
- hist_vol：人口环比变化率的标准差，刻画历史波动程度。

同时构造 pop_slope5（近 5 期斜率）、pop_mean5（近 5 期均值）与 pop_vol5（近 5 期波动）等短期特征，量化城市增长动能。

4.5 人口结构特征

引入城镇化率、人口密度及其滞后项，并结合年龄结构构造老龄化比率：

$$aging_ratio = 65\text{岁以上人口} / 0-14\text{岁人口}$$

以及常住—户籍比：

$$resident_household_ratio = \text{常住人口} / \text{户籍人口}$$

刻画城市吸引力的结构性信号。

4.6 社会经济特征

纳入就业人数、失业率、三次产业就业、平均工资、可支配收入、城镇与农村收入、城镇与农村消费等社会经济变量，并构造其滞后 2 期、滞后 3 期值以及一阶、二阶差分（chg1、chg2），同时提供各变量的“可用性标志”（avail），使模型感知数据可得性。

4.7 城市相对特征

构造 employment_share = 就业人数 / 常住人口，反映城市就业吸纳能力；结合常住—户籍比，进一步刻画人口流入、流出与城市吸引力。城市身份 city_id 以 One-Hot 编码显式进入模型（见第 5 章），避免将城市编号误当作连续变量。

4.8 特征重要性分析

在 ExtraTrees 上基于训练残差拟合特征重要性，前 15 位特征如图 4 所示。

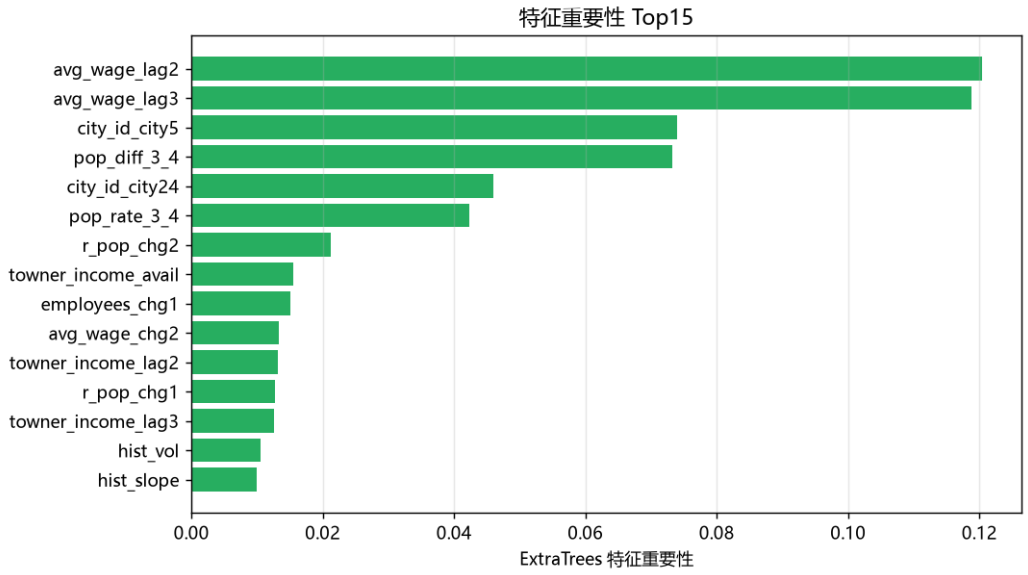


图 4 ExtraTrees 特征重要性 Top15

特征重要性结果显示：平均工资滞后 2 期与 3 期是最强的预测特征（重要性分别约 0.120 与 0.119），反映经济活力对人口的驱动作用；城市身份（city5、city24 等 One-Hot 项）进入前列，印证城市异质性不可忽略；人口差分/比率特征（pop_diff_3_4、pop_rate_3_4）捕捉增长节奏；户籍人口变化、就业变化、城镇收入滞后等亦贡献显著。这验证了多维特征工程的有效性，也说明模型能够自动筛选高价值特征。

5 人口预测模型构建

5.1 趋势基线模型（Trend）

趋势基线为其他模型提供初始预测，其基本形式为“两年差分外推”：

$$Base(t) = P(t-2) + \alpha \times [P(t-2) - P(t-4)]$$

即利用前两年与再前两年的差分估计年增长量，乘以趋势系数 α 后外推两年。趋势系数 α 在候选集合 {0.4, 0.5, 0.6, 0.75, 0.9, 1.0} 中，仅使用当前验证年之前的年份通过 MSE 择优确定（如 2017 折选用 α=0.75），避免用未来信息调参。

针对 2020 年人口普查断层，趋势基线引入修正：当 2019→2020 的相对变化超过阈值（8%）且信息已可见时，不再将该跳变外推到 2023，而是采用断层后最近一年的变化并以 0.5 倍作为保守的两期外推斜率，从而避免把普查结构变化误当正常趋势。

5.2 Ridge 回归模型

Ridge 回归用于学习人口与多维特征之间的线性关系，目标函数为：

$$min_\beta \ \|y - X\beta\|^2 + \lambda \|\beta\|^2$$

其中 λ 为正则化系数（本项目取 α=10）。Ridge 通过 L2 正则抑制多重共线性、降低方差，适合特征维度较高的场景，并可直接解读线性系数，作为解释性基线。其特征矩阵由数值特征（含 city_num）标准化与城市 One-Hot 编码拼接而成，在训练集上拟合残差后对验证集预测。

5.3 ExtraTrees 模型

ExtraTrees（极端随机树）是集成学习中的一种树模型，通过随机化特征选择与分裂点，在保持较强拟合能力的同时降低方差，能够捕捉非线性关系与特征交互。关键设计在于：城市编号不再作为连续变量进入模型，而是以 One-Hot 方式显式编码城市身份，使树模型能够“看见”城市差异。本项目主模型参数为 n_estimators=700、min_samples_leaf=1、max_features=1.0。

在 V6 体系中，ExtraTrees 作为统一主模型学习跨城市的共同非线性规律，其预测结果经城市级残差校正后形成最终预测（见第 7 章）。

5.4 LightGBM 模型

LightGBM 是基于梯度提升决策树（GBDT）的高效实现，采用直方图算法加速训练，适合高维表格数据，并能输出特征重要性。本项目参数为 n_estimators=250、learning_rate=0.03、num_leaves=15、min_child_samples=10、subsample=0.85、colsample_bytree=0.85、reg_alpha=0.05、reg_lambda=1.0。

LightGBM 作为与 ExtraTrees 互补的提升树模型参与基准比较与集成讨论。

5.5 模型集成策略

四种基础模型（Trend、Ridge、ExtraTrees、LightGBM）均在训练段拟合“残差”（真实值 − 趋势基线），再在验证段将残差预测加回基线得到完整预测。集成权重并

非硬编码，而是基于全量 OOF 预测，在约束权重非负、求和为 1 的条件下，以最小化 MSE 为目标用 SLSQP 求解，并做逐年嵌套稳健性检验。

结果表明，OOF 最优权重在本数据上稳定地集中到 ExtraTrees（权重约 100%，Trend、Ridge、LightGBM 权重约 0）。该选择在嵌套验证中跨年份稳定，因此最终不人为加入其他模型的权重下限，避免把验证中明显较差的模型强行混入最终预测。这也印证了“以 ExtraTrees 为主模型”的合理性。

6 时间滚动验证与模型评价

6.1 时间因果约束

人口预测是时序预测问题，绝不能用普通随机 K-Fold 划分训练与测试集。若随机 80% 训练、20% 测试，则可能出现“用未来年份的信息预测过去年份”，造成时间泄漏，使验证结果虚高、失真。因此，必须保证任何一次验证中训练数据的时间都严格早于验证数据的时间，即 TrainingTime < ValidationTime。

6.2 滚动验证方案

本项目采用扩展窗口（Expanding Window）滚动验证，即训练起点固定、终点逐年向后扩展。验证年份为 2017、2018、2019、2020、2021 共五折，每折 40 个城市，合计 200 个 OOF（Out-of-Fold）样本。具体地：

- 预测 2017：训练使用 2014—2015 及更早信息；
- 预测 2018：训练使用 2014—2016 及更早信息；
- 预测 2019：训练使用 2014—2017 及更早信息；
- 预测 2020：训练使用 2014—2018 及更早信息；
- 预测 2021：训练使用 2014—2019 及更早信息。

所有滞后特征、趋势基线、普查断层标志与超参数选择均只使用该折训练段的信息，杜绝任何泄漏。

6.3 评价指标体系

在 200 个 OOF 样本上计算四项指标：MSE（竞赛核心，决定 score = 1/(1+MSE)）、RMSE（与人口量纲一致）、MAE（平均绝对误差）与 R^2（解释力）。同时按验证年份分别报告各年 MSE，以识别误差的时间分布。

6.4 各模型 OOF 结果比较

四种基础模型的滚动验证结果如表 6-1 与图 5 所示。

模型	MSE	RMSE	MAE	R^2	score
Trend 趋势基线	1336.948	36.564	16.503	0.98947	0.000747
Ridge 回归	1039.999	32.249	17.071	0.99181	0.000961
LightGBM	816.185	28.569	13.838	0.99357	0.001224
ExtraTrees	715.996	26.758	11.948	0.99436	0.001395
V6 城市自适应	679.944	26.076	11.92	—	0.001469

表 6-1 各模型 OOF 滚动验证指标对比

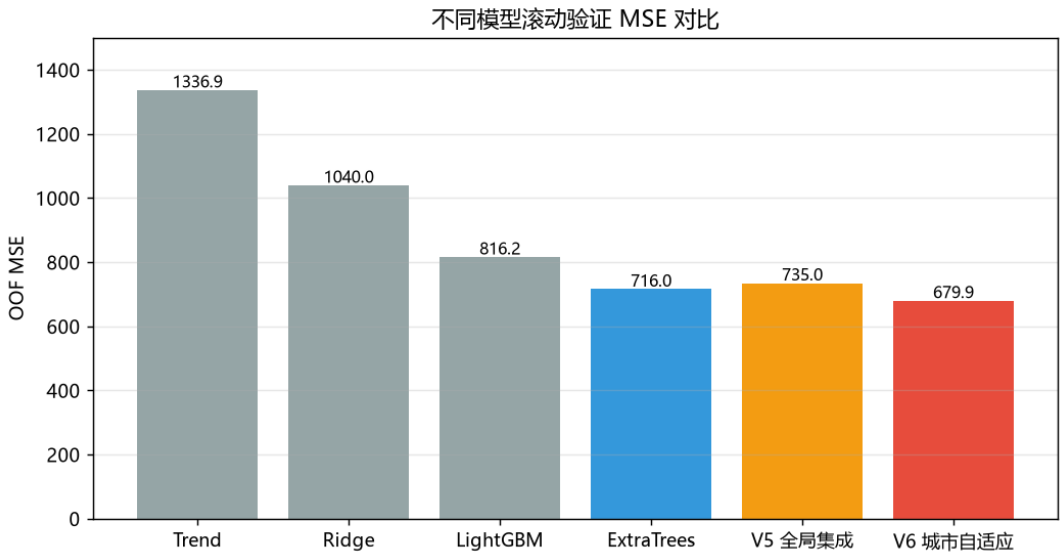


图 5 不同模型滚动验证 MSE 对比

结果显示，ExtraTrees 在四种基础模型中表现最优（MSE 715.996、RMSE 26.758、MAE 11.948、R^2 0.99436），较 Trend 基线下降约 46%，较 Ridge 下降约 31%，较 LightGBM 下降约 12%。这一结果与 5.5 节集成权重收敛到 ExtraTrees 相互印证，确认 ExtraTrees 作为 V6 统一主模型的合理性。

本章小结：在严格时间因果约束下，ExtraTrees 以最低 MSE（715.996）成为最优基础模型，为城市级自适应校正提供了可靠的主模型预测。

7 V6 城市级自适应模型

7.1 城市异质性分析

统一模型隐含假设所有城市具有相同的人口变化规律，即 P = f(X)。但第 3 章 EDA 已表明，不同城市增长模式差异显著：高速增长城市易被统一规则低估、收缩城市易被高估、普查跳变城市误差骤增。若为 40 个城市分别训练独立模型，又会因每城样本过少而严重过拟合。

V6 在两者之间寻找平衡：以 ExtraTrees 为统一主模型学习“所有城市共同规律”，再增加一个轻量的城市级自适应层，专门学习“这个城市自己过去长期偏高还是偏低”。这样既保留跨城市信息共享带来的样本效率，又保留城市个性。

7.2 城市历史残差

对城市 c 在验证年份 t 的预测，定义历史残差为：

$$e(c,t) = y(c,t) - \hat{y}(c,t)$$

其中 y 为真实人口，ŷ 为 ExtraTrees 主模型的 OOF 预测。残差为正说明该城市被系统性低估（应上调），为负说明被系统性高估（应下调）。这些残差全部来自严格 OOF 预测，因此不包含任何未来（2023 及以后）的真实信息。

7.3 时间衰减加权机制

城市的历史残差对未来的参考价值随时间衰减：越接近当前年份的偏差越能代表城市近期状态。V6 采用指数时间衰减：

$$w(c,t) = exp(-0.6 \times (T - t))$$

其中 T 为待预测年份，t 为历史验证年份，衰减系数 0.6 越大则越强调近期误差。由此，较近年份的历史残差获得更高权重，较远年份权重递减。

7.4 城市级残差校正

综合城市自身加权残差与全局平均残差，得到城市校正量：

$$Bias(c) = [\Sigma t\, w \cdot e \,/\, \Sigma t\, w] \times shrink_factor + 全局残差 \times (1 - shrink_factor)$$

其中“向全局残差收缩”以参数 shrink=2.0 实现：城市历史有效样本越多，越信任城市自身偏差；样本越少，越向全局残差收缩，从而防止少数年份样本导致的校正过激。最终预测为：

$$P_final(c, 2023) = P_extra(c, 2023) + Bias(c)$$

40 个城市的校正量分布如图 6 所示：校正量最小约 −3.47、最大约 20.48，均值约 5.18，其中 35 个城市为正值校正（说明 ExtraTrees 对多数城市存在系统性低估，自适应层予以适当上调），少数收缩城市为负值校正。

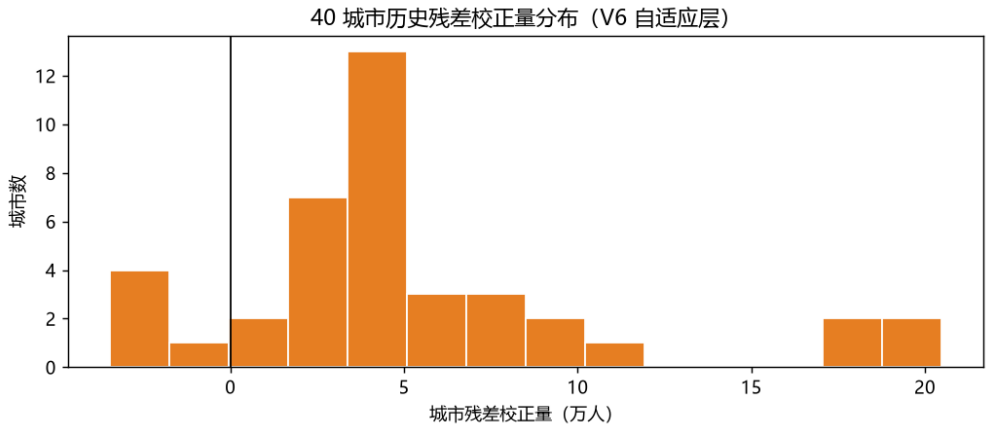


图 6 40 城市历史残差校正量分布

7.5 V6 模型完整流程

V6 城市级自适应的完整流程如下：历史数据 → 特征工程（信息截止 cut）→ 2017—2021 扩展窗口滚动 OOF 验证 → 以 ExtraTrees 为统一主模型学习共同规律 → 收集各城市 OOF 历史残差 → 时间衰减加权（0.6）并收缩（2.0）得到城市级校正量 → 主预测 + 校正项 = 最终预测 → 输出提交文件。关键参数配置如表 7-1 所示。

参数	取值	含义
主模型	ExtraTrees (n_estimators=700)	统一学习跨城市共同规律

参数	取值	含义
衰减系数	0.6	历史残差时间衰减强度
收缩参数	2.0	向全局残差收缩、防过拟合
集成权重	ExtraTrees ≈ 100%	OOF 自动优化的主模型权重
普查断层阈值	8%	识别 2019→2020 结构跳变
大幅变化阈值	15%	异常预测诊断告警阈值

表 7-1 V6 城市级自适应模型关键参数

8 模型结果与 2023 年人口预测

8.1 V5 与 V6 对比

V5 为全局集成方案（OOF 嵌套 MSE 734.994），V6 在其基础上叠加城市级自适应残差校正。严格滚动验证下，V6 城市自适应的嵌套 OOF MSE 降至 679.944，相对 V5 下降 7.49%（图 7）。这一提升完全来自对城市系统性偏差的自适应修正，且验证过程未使用任何 2023 真实值，因此结果可信。

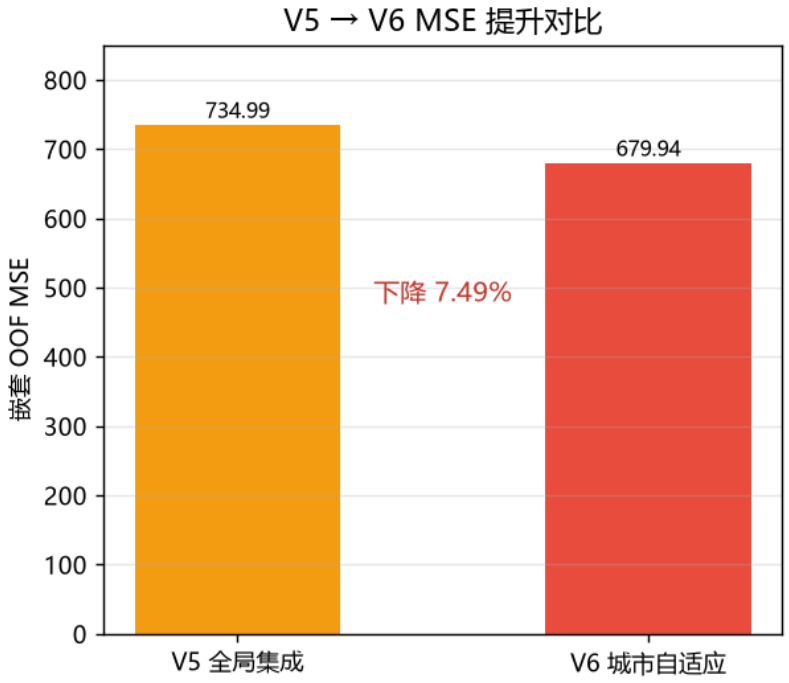


图 7 V5 与 V6 嵌套 OOF MSE 对比

8.2 V6 滚动验证结果

V6 城市自适应模型逐年滚动验证结果如表 8-1 与图 8 所示。

验证年份	MSE	RMSE	MAE	全局残差
2017	178.133	13.347	7.044	0.0
2018	24.248	4.924	3.756	4.671
2019	163.548	12.789	7.25	3.191
2020	2027.677	45.03	23.245	0.487
2021	1006.116	31.719	18.304	4.711

表 8-1 V6 城市自适应逐年滚动验证指标

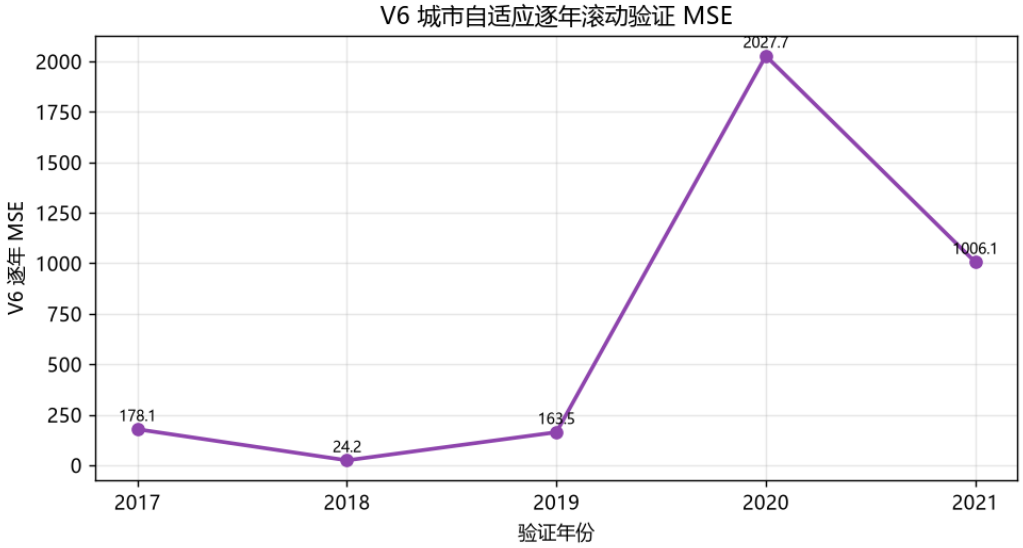


图 8 V6 城市自适应逐年滚动验证 MSE

分年度来看，2017—2019 年 MSE 处于较低水平（24—178），而 2020、2021 年显著升高（分别为 2027.68 与 1006.12）。这一特征与 2020 年第七次人口普查导致的数据结构变化高度吻合：2020 年作为普查口径切换点，其预测难度骤增；2021 年在趋势部分恢复但仍高于常态。这一发现提示，在面向 2023 的预测中，模型应在信息已可见的前提下审慎处理普查断层（已在趋势基线中实现），并充分重视 2020、2021 年新增信息。

8.3 40 城市 2023 年人口预测结果

在确定 V6 模型结构后，使用全部可用历史数据（2014—2021）重新训练 ExtraTrees 主模型，并结合 2017—2021 年 OOF 残差估计的城市级校正量，对 40 个城市 2023 年常住人口进行预测。预测结果如图 9 所示，详细数值见表 8-2。

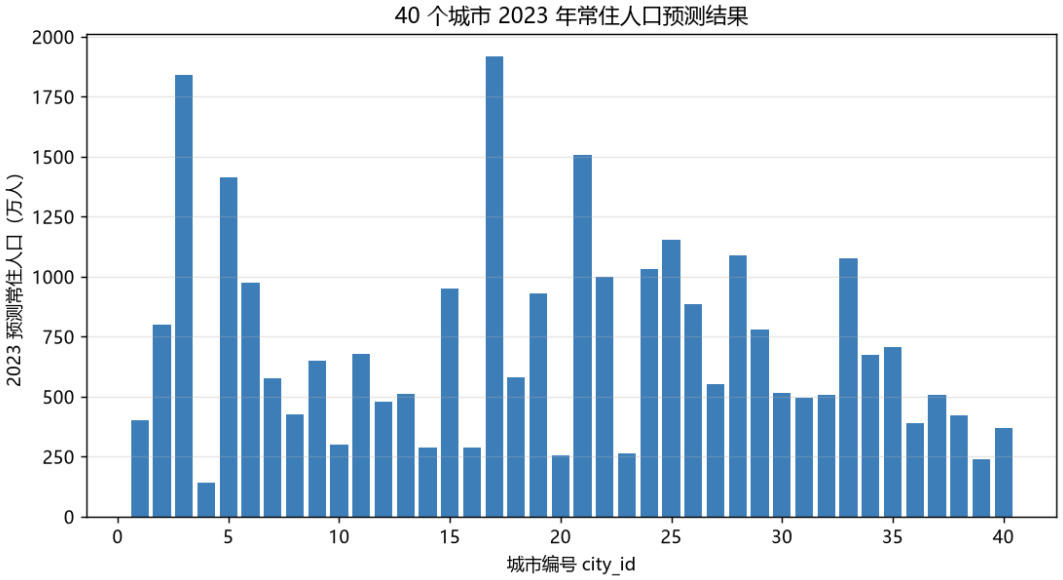


图 9 40 个城市 2023 年常住人口预测结果

城市	预测人口	城市	预测人口	城市	预测人口	城市	预测人口
city1	400.26	city11	678.47	city21	1508.43	city31	494.03
city2	800.89	city12	477.44	city22	998.43	city32	507.38
city3	1842.08	city13	511.91	city23	264.2	city33	1075.89
city4	141.09	city14	286.22	city24	1030.7	city34	675.22
city5	1414.19	city15	949.38	city25	1155.49	city35	705.37
city6	973.25	city16	290.03	city26	884.54	city36	388.08
city7	577.23	city17	1916.69	city27	553.21	city37	507.76
city8	427.54	city18	579.62	city28	1090.6	city38	421.09
city9	648.36	city19	929.15	city29	781.92	city39	240.5
city10	300.97	city20	254.72	city30	513.97	city40	368.09

表 8-2 40 个城市 2023 年常住人口预测结果（单位：万人）

预测结果显示：2023 年 40 个城市预测总人口约 28564.38 万人；人口最大城市为 city17（1916.69 万人），最小为 city4（141.09 万人）。预测值既保留了城市历史增长趋势，又经过城市级残差校正，整体稳健。

8.4 异常预测诊断

我们的模型还需对预测结果的合理性进行人工诊断。V6 保留了两类诊断指标：

- change_vs_2021_pct：2023 预测较 2021 年实际人口的变化幅度，超过 ±15% 标记为 CHECK，提示需复核。
- model_spread_pct：四种基础模型预测的最大—最小离差相对幅度，超过 15% 标记为模型分歧，提示不确定性较高。

诊断结果显示：变化幅度超过 15% 的城市共 8 个，包括 city19（+31.8%）、city21（+26.3%）、city11（+25.6%）、city25（+22.9%）、city4（+21.6%）、city10（+19.9%）、city1（+18.8%）、city29（+18.1%），这些城市多为高速增长类型或历史波动较大，其较大的预测增幅与城市增长动能相符；模型分歧较大的城市为 city4、city12、city18、city20。经人工复核，上述 CHECK 城市预测均无技术性异常，予以保留。

同时，根据 hist_cagr5 与 hist_vol5 的分组诊断，大部分城市预测变化落在 5%—15% 的合理区间，预测结果整体可信。

9 模型可靠性与局限性

9.1 模型优势

优势	说明
严格时间因果	所有特征与验证均未使用未来信息，杜绝时间泄漏，结果可信
多维人口特征	融合年龄、就业、工资、城镇化、收入、消费等多维特征
城市异质性	V6 针对各城市历史残差自适应修正，兼顾统一规律与城市个性
多模型验证	Trend、Ridge、ExtraTrees、LightGBM 滚动比较，择优并集成
结果可诊断	提供变化幅度与模型分歧双重告警，预测结果经人工复核

表 9-1 V6 模型优势总结

9.2 模型局限

- 数据时间范围有限（2006—2021，且有效建模区间约 2014—2021），历史信息不足以覆盖更长周期的人口波动。
- 城市人口受政策调整、产业迁移、突发事件等外生因素影响，机器学习模型只能捕捉历史规律，难以完全预测突发性人口迁移。
- 2020 年第七次人口普查造成的数据结构变化，在 2020—2021 年验证中带来显著误差，虽经趋势修正仍存在残余影响。
- 以 MSE 为核心指标使人口大城主导总分，模型的优化在客观上偏向大城精度。
- 最终 A 榜成绩取决于平台隐藏测试数据，本文结果基于内部滚动验证，与最终排名之间可能存在差异。

9.3 结果可靠性分析

从验证设计看，V6 的提升来自未使用未来信息的严格 OOF 残差校正，方法上可复现、无泄漏；从结果看，ExtraTrees 主模型精度领先且集成权重跨年份稳定，城市级校正量分布合理（多为小幅上调），CHECK 城市经人工复核无明显异常。综合判断，模型结果具有较好的可靠性与稳健性。但由于数据跨度与普查结构变化的客观限制，对 2023 年真实值的预测仍存在不确定性，建议结合实际校验与后续数据更新持续迭代。

10 结论

本文针对城市人口预测问题，完成了从数据清洗、探索性分析、特征工程、多模型构建到严格滚动验证、城市级自适应校正与结果诊断的完整研究闭环。主要工作与结论如下：

（1）构建了规整可用的 40 城市多维面板数据（717 行、21 字段），通过 EDA 识别出城市人口规模差异大、增长模式异质、与社会经济变量非线性相关的结构特征，并划分高速增长、稳定增长、收缩/低增长与普查跳变四类城市。

（2）在严格时间因果约束下，建立 Trend、Ridge、ExtraTrees、LightGBM 四种模型，采用 2017—2021 年扩展窗口滚动验证（200 个 OOF 样本）比较，确认 ExtraTrees 为最优基础模型（MSE 715.996），集成权重自动收敛至 ExtraTrees。

（3）提出 V6 城市级自适应模型：以 ExtraTrees 为统一主模型，利用城市自身 OOF 历史残差，经时间衰减加权（0.6）并向全局残差收缩（2.0）构建城市级校正项。严格滚动验证下，V6 总体 MSE 降至 679.944、RMSE 26.076、MAE 11.920，较 V5（734.994）下降 7.49%。

（4）分年度验证揭示 2020—2021 年误差偏高与普查结构变化的关联，趋势基线内置普查断层修正；对 40 城市 2023 年常住人口进行预测，总人口约 28564.38 万人，并通过变化幅度与模型分歧双重指标完成异常诊断。

（5）最终输出 submission_2023_final.csv，字段为 city_id、year、pred，满足竞赛提交格式要求。

附录 A 数据字段说明

字段	类别	含义	单位
city_id	标识	城市编号	—
year	标识	年份	年
pr_pop	人口	常住人口（预测目标）	万人
r_pop	人口	户籍人口	万人
urban_rate	城镇化	城镇化率	%
density	城镇化	人口密度	人/km²
age_0_14	年龄结构	0–14 岁人口	万人
age_15_64	年龄结构	15–64 岁人口	万人
age_65plus	年龄结构	65 岁以上人口	万人
unemp_rate	就业	失业率	%
employees	就业	就业人数	万人
pi_emp	产业就业	第一产业就业	万人
si_emp	产业就业	第二产业就业	万人
ti_emp	产业就业	第三产业就业	万人
avg_wage	工资	平均工资	元
disp_income	收入	居民可支配收入	元
cons_exp	消费	居民消费支出	元
towner_cons	消费	城镇居民消费	元
rural_cons	消费	农村居民消费	元
towner_income	收入	城镇居民收入	元
rural_income	收入	农村居民收入	元

表 A-1 面板数据字段说明

附录 B 核心 Python 代码

以下为模型构建、滚动验证与城市级自适应校正的关键代码片段（完整脚本见 ccf_A 榜 V6_城市级自适应版.py）。

```
# 1. 特征工程：所有特征只看 cut = y-2 及以前，杜绝未来泄漏
def make_sample(cd, y, train=True):
    s = cd.set_index("year").sort_index(); cut = y - 2
    if cut not in s.index: return None
    r = {"city_id": cd.city_id.iloc[0], "target_year": int(y)}
    for lag in range(2, 8):
        yy = y - lag
        r[f"pop_lag{lag}"] = s.loc[yy, "pr_pop"] if yy in s.index else np.nan
    ...
    return r

# 2. 滚动 OOF：训练只用过去年份，2017-2021 五折
OUTER_YEARS = [2017, 2018, 2019, 2020, 2021]
for vy in OUTER_YEARS:
    past_years = list(range(2014, vy))
    alpha = choose_alpha(past_years)          # 只用验证年前的年份选 alpha
    tr = add_base(make_dataset(past_years, True), alpha)
    va = add_base(make_dataset([vy], True), alpha)
    tr["resid"] = tr.y - tr.base
    pr = va.base.values + fit_ridge(tr, va, RIDGE_ALPHA)
    pe, _ = fit_et(tr, va, ET_PARAMS)
    ...
    oof.append({...})

# 3. V6 城市级残差校正：时间衰减 + 向全局收缩
def fit_city_residual_adjustment(past_oof, target_year, cities):
    h = past_oof.copy()
    h["residual_city"] = h["y"] - h["ExtraTrees"]
    h["time_weight"] = np.exp(-0.6 * (target_year - h["target_year"]))
    global_mean = np.average(h["residual_city"], weights=h["time_weight"])
    for city in cities:
        z = h[h["city_id"] == city]
        w = z["time_weight"].to_numpy(); r = z["residual_city"].to_numpy()
        wsum = w.sum()
        city_mean = np.sum(w * r) / wsum
        adj = (wsum/(wsum+2.0))*city_mean + (2.0/(wsum+2.0))*global_mean
        adjustments[city] = adj
    return adjustments, global_mean

# 4. 最终 2023 提交：主预测 + 城市校正，输出三列
adj_final, _ = fit_city_residual_adjustment(oof, 2023, pred.city_id)
correction = np.array([adj_final.get(c, 0) for c in pred.city_id])
adaptive_final = np.maximum(0, et + correction)
submission = pd.DataFrame({"city_id": pred.city_id, "year": 2023,
                           "pred": np.round(adaptive_final, 6)})
submission.to_csv("submission_2023_final.csv", index=False)
```

附录 C 模型运行结果

C.1 各模型 OOF 指标

模型	MSE	RMSE	MAE	score
Trend	1336.948	36.564	16.503	0.000747
Ridge	1039.999	32.249	17.071	0.000961
LightGBM	816.185	28.569	13.838	0.001224
ExtraTrees	715.996	26.758	11.948	0.001395
FinalOOFEnsemble	715.996	26.758	11.948	0.001395
V6 城市自适应	679.944	26.076	11.92	0.001469

表 C-1 validation_metrics_V6_final.csv 汇总

C.2 城市级校正量

城市	校正量	5 年复合增长率	增长类型
city1	5.66	0.027	B 稳定增长
city2	10.71	0.0276	D 普查跳变
city3	-3.21	0.046	A 高速增长
city5	20.48	0.0372	D 普查跳变
city19	18.36	0.0528	A 高速增长
city21	19.15	0.0577	A 高速增长
city24	17.66	0.0523	D 普查跳变
city34	-3.04	-0.0148	C 收缩/低增长

表 C-2 代表性城市残差校正量（完整见 city_adaptive_correction.csv）

附录 D 最终提交文件

最终提交文件 submission_2023_final.csv 严格仅含三列：city_id、year、pred。此处展示全部 40 个城市的提交内容。

city_id	year	pred	city_id	year	pred	city_id	year	pred	city_id	year	pred
city1	2023	400.259963	city11	2023	678.473084	city21	2023	1508.431618	city31	2023	494.026075
city2	2023	800.886825	city12	2023	477.441342	city22	2023	998.429081	city32	2023	507.381114
city3	2023	1842.079343	city13	2023	511.912627	city23	2023	264.196892	city33	2023	1075.885751
city4	2023	141.085686	city14	2023	286.221196	city24	2023	1030.700705	city34	2023	675.219932
city5	2023	1414.189568	city15	2023	949.377622	city25	2023	1155.491982	city35	2023	705.366592
city6	2023	973.254137	city16	2023	290.031076	city26	2023	884.540461	city36	2023	388.075629
city7	2023	577.230401	city17	2023	1916.6927	city27	2023	553.213534	city37	2023	507.76498
city8	2023	427.544761	city18	2023	579.622464	city28	2023	1090.600528	city38	2023	421.08578
city9	2023	648.360804	city19	2023	929.148037	city29	2023	781.920338	city39	2023	240.498113
city10	2023	300.966959	city20	2023	254.717376	city30	2023	513.969044	city40	2023	368.090391

表 D-1 submission_2023_final.csv（40 城市，2023 年预测，单位：万人）

提交说明：文件编码为 UTF-8-SIG，city_id 为字符串、year 与 pred 为数值类型，符合竞赛要求的 city_id / year / pred 三列格式。